

Анализ статьи OpenVLA: An Open-Source Vision-Language-Action Model

Ссылка на статью: <https://proceedings.mlr.press/v270/kim25c.html>

GitHub репозиторий с экспериментом: https://github.com/sene4ga/Paper_analysis

Введение

Vision-Language-Action (VLA) модели являются одним из наиболее активно развивающихся направлений современной робототехники. Подобные системы объединяют обработку изображений, естественного языка и управление роботами, позволяя интерпретировать текстовые инструкции и выполнять действия в физической среде.

Для анализа была выбрана статья *OpenVLA: An Open-Source Vision-Language-Action Model*, представленная на CoRL 2025. Работа представляет особый интерес благодаря открытому исходному коду, опубликованным весам модели и возможности воспроизводимого fine-tuning, что выгодно отличает её от большинства закрытых VLA-систем.

Описание метода

В основе OpenVLA лежит крупная языковая модель Llama 2, дополненная визуальными признаками DINOv2 и SigLIP. На вход система получает изображение сцены и текстовую инструкцию, после чего генерирует последовательность действий робота в авторегрессионном режиме.

Ключевой особенностью работы является дискретизация действий. Вместо предсказания непрерывных управляющих сигналов авторы кодируют действия в виде токенов, аналогично тексту в больших языковых моделях. Это позволяет применять методы масштабирования LLM и instruction tuning для робототехнических задач.

В отличие от diffusion-based policy methods, OpenVLA формулирует управление как задачу последовательной генерации действий. Такой подход обеспечивает хорошую масштабируемость и универсальность, однако может приводить к накоплению ошибок и увеличению inference latency при длинных последовательностях действий.

Обучение проводится на наборе Open X-Embodiment, содержащем около 970 тысяч робототехнических демонстраций, что позволяет модели обобщать навыки между различными задачами и роботами.

Основные задачи статьи

Основной задачей работы является создание полностью открытой foundation-модели для робототехники. Авторы стремятся обеспечить воспроизводимость результатов и возможность дальнейшего развития модели исследовательским сообществом.

Второй задачей является эффективный transfer learning на новые робототехнические сценарии. Авторы показывают, что OpenVLA может быть адаптирована к новым задачам значительно быстрее по сравнению с обучением политик управления с нуля.

Также работа исследует вычислительную эффективность обучения. В статье демонстрируется возможность fine-tuning на потребительских GPU с использованием LoRA-адаптации и квантизации.

Предлагаемое улучшение и эксперимент

Одним из ограничений OpenVLA является использование равномерной дискретизации действий. При небольшом числе токенов это приводит к потере точности управления, а при большом — увеличивает размер action vocabulary.

В качестве улучшения была предложена adaptive discretization strategy, использующая более плотное разбиение пространства действий вблизи нуля, где требуется высокая точность манипуляций.

Для проверки гипотезы был проведён небольшой эксперимент на синтетических управляющих сигналах. Сравнивались uniform и adaptive discretization при одинаковом числе токенов. В качестве метрики использовалась среднеквадратичная ошибка восстановления (MSE).

Метод	Reconstruction MSE
Uniform discretization	0.0058
Adaptive discretization	0.0031

Таблица 1: Сравнение стратегий дискретизации

Метод	Success rate	Тип действий
Diffusion Policy	72.4	Continuous
Octo	75.1	Hybrid
OpenVLA	76.5	Tokenized

Таблица 2: Сравнение методов на задачах LIBERO

Дополнительно был проведён сравнительный анализ существующих VLA-подходов.

Полученные результаты показывают, что adaptive discretization позволяет более точно представлять непрерывные управляющие сигналы без увеличения размера action vocabulary. Это может повысить качество low-level управления и уменьшить потери, связанные с квантованием действий в VLA-моделях.

Преимущества и ограничения

Ключевым достоинством OpenVLA является открытость модели и инструментов обучения. Работа существенно повышает воспроизводимость исследований в области VLA-моделей.

Другим преимуществом является универсальность архитектуры и способность к transfer learning между различными робототехническими задачами.

Тем не менее модель имеет ряд ограничений. Авторегрессионная генерация действий может увеличивать inference latency, что критично для real-time управления роботами. Кроме того, дискретизация действий потенциально ограничивает точность low-level контроля по сравнению с continuous-control методами.

Также работа содержит ограниченный анализ long-horizon planning и устойчивости модели к out-of-distribution сценариям.

Возможные направления развития

Перспективным развитием OpenVLA представляется гибридная архитектура, сочетающая дискретное высокоуровневое планирование и непрерывный low-level контроллер. Это позволило бы сохранить преимущества foundation-моделей и одновременно повысить точность управления.

Дополнительно интерес представляет интеграция world models для прогнозирования последствий действий до их выполнения, что может улучшить качество long-horizon planning.

Заключение

Статья *OpenVLA: An Open-Source Vision-Language-Action Model* представляет собой значимую работу в области интеллектуальной робототехники. Авторам удалось продемонстрировать, что открытая foundation-модель способна эффективно конкурировать с современными VLA-подходами и адаптироваться к новым задачам.

Проведённый эксперимент показывает, что adaptive discretization может стать перспективным направлением развития OpenVLA, позволяя уменьшить ошибку квантования действий без увеличения сложности модели.